Guia Didático da Parte 2: Árvore de Decisão

Teoria, Intuição, Aplicação em Redes e Roteiro de Apresentação

Público-Alvo: Estudantes de TI (foco em intuição antes da fórmula)	**Módulo:** Parte 2 — Teoria I (Árvore de Decisão)
Papel no Artigo: Conceito-base supervisionado	**Tempo na Apresentação:** ~50 segundos

1. A Intuição: O que é uma Árvore de Decisão?

Pense no jogo **Akinator** ou em uma **triagem médica de pronto-socorro**. Quando um paciente chega com febre, o médico não chuta o diagnóstico; ele realiza perguntas sequenciais ordenadas por relevância: *'A temperatura está acima de 38°C?'*, *'Tem falta de ar?'*, *'Há dor de garganta?'*.

No Aprendizado de Máquina, a **Árvore de Decisão** opera com essa exata lógica sobre os pacotes de rede. Ela analisa as métricas da rota (como z_robusto, perda_pct e jitter_relativo) e estabelece uma sequência ótima de regras de 'Sim ou Não' para classificar o fluxo em **OK**, **RISCO** ou **FALHA**.

2. Anatomia da Árvore (Terminologia Essencial)

A estrutura é composta por quatro elementos principais:

- **Nó Raiz (Root Node):** O ponto de partida. Realiza a primeira pergunta, avaliando o atributo que mais separa o tráfego saudável das anomalias (em nosso projeto, o z_robusto).
- **Nós Internos (Decision Nodes):** Perguntas intermediárias que refinam o diagnóstico à medida que a árvore se aprofunda.
- **Ramos (Branches):** As bifurcações que conectam os nós, representando as respostas às condições (ex: *z_robusto > 3.0 = Verdadeiro / Falso*).
- **Folhas (Leaf Nodes):** Os nós terminais da árvore. Não contêm mais perguntas; entregam a classe final predita (OK, RISCO ou FALHA).

```
[ NÓ RAIZ: z_robusto > 3.0? ] / \ (Sim) / \ (Não) / \ [ NÓ INTERNO: n5_risco > 2? ] ( FOLHA: OK ) / \ (Sim) / \ (Não) / \ ( FOLHA: FALHA ) ( FOLHA: RISCO )
```

3. Como a IA Escolhe a Pergunta? (Critérios de Pureza)

Como o computador decide qual pergunta fazer primeiro sem intervenção manual? Imagine uma urna com bolas verdes (OK), amarelas (RISCO) e vermelhas (FALHA) completamente misturadas. O objetivo da árvore é encontrar uma linha de corte que separe essas cores da forma mais uniforme possível.

Essa 'bagunça' ou grau de mistura de uma amostra é calculada por métricas estatísticas de **impureza**:

- **Índice Gini:** Mede a probabilidade de um elemento ser classificado incorretamente caso receba um rótulo aleatório. Varia de 0 (pureza total, apenas uma classe no nó) a valores próximos de 0.5 ou mais (mistura total).
- **Entropia:** Baseada na Teoria da Informação de Shannon. Mede a desordem dos dados em bits. Entropia 0 indica pureza absoluta.

O algoritmo testa exaustivamente todos os atributos e pontos de corte possíveis, escolhendo aquele que entrega o maior **Ganho de Informação** (a maior redução imediata da impureza).

4. O Grande Perigo: Overfitting e Alta Variância

Se uma árvore de decisão puder crescer indefinidamente, ela continuará se ramificando até criar uma regra exclusiva para cada amostra específica da base de treino. O resultado é o **Overfitting (Superajuste)**: o modelo atinge 100% de acerto decorando o histórico, mas perde totalmente a capacidade de generalizar diante de dados reais futuros.

Dizemos que árvores isoladas sofrem de **Alta Variância** (pequenas perturbações no dataset de treino alteram completamente sua estrutura).

Mecanismos de Controle Aplicados no Projeto:

- **Profundidade Máxima (max_depth):** Limita o número máximo de perguntas sequenciais (ex: profundidade 4 ou 5), forçando a árvore a captar apenas padrões amplos.
- **Poda (Pruning):** Remoção programada de ramos com baixo ganho discriminante, eliminando ramificações que atendem apenas a ruídos de rede.

5. Exemplo Prático com os Dados do Nosso Projeto

Considere um pacote trafegando na rota intercontinental **São Paulo ➔ Amsterdã** coletado via RIPE Atlas:

Passo 1 (Nó Raiz):	A árvore pergunta: z_robusto > 3.0? (A latência atual desviou mais de 3 desvios robustos da mediana histórica dessa rota?). Se **Não**, vai para folha **OK**.
Passo 2 (Nó Interno):	Se **Sim**, a árvore testa: n5_risco > 2? (Dos últimos 5 pacotes dessa mesma rota, mais de 2 já exibiram comportamento anômalo?).
Passo 3 (Folha Final):	Se **Sim**, classifica como **FALHA** (degradação persistente). Se **Não**, classifica como **RISCO** (anomalia pontual ou jitter transitório).

6. Texto-Base Sugerido para o Artigo HTML/MD

2.1 Árvore de Decisão: A Base do Diagnóstico Estruturado

A Árvore de Decisão fundamenta o aprendizado supervisionado deste trabalho através de um modelo intuitivo semelhante a um fluxograma hierárquico. Estruturada a partir de um **Nó Raiz**, **Nós Internos** de teste e **Folhas** com as categorias finais (OK, RISCO ou FALHA), a árvore particiona o espaço de atributos da rede avaliando o *Índice Gini* ou a *Entropia* para maximizar a pureza de cada divisão.

Sua principal vantagem operacional reside na **alta interpretabilidade** (modelo 'caixa-branca'), permitindo que engenheiros de infraestrutura auditem e validem visualmente os limites lógicos que acionam cada alarme. Entretanto, árvores sem restrição exibem alta variância e suscetibilidade severa ao **overfitting**. Em nosso pipeline, mitigamos essa fragilidade parametrizando a profundidade máxima (max_depth) via busca em grade (*GridSearchCV*), preservando a capacidade de generalização do modelo em novos fluxos.

7. Roteiro Cronometrado para a Apresentação Oral (~50 segundos)

*"Olá a todos! Eu sou o responsável por apresentar a **Árvore de Decisão**, o alicerce comparativo da nossa pesquisa.*

*A Árvore funciona como um fluxograma lógico direto: diante de um pacote de rede, ela faz perguntas sequenciais de 'Sim ou Não'. Começamos pelo **nó raiz** com o teste mais relevante — no nosso caso, se o desvio relativo z_robusto superou o limiar —, percorremos os **ramos** e alcançamos as **folhas**, que entregam o veredito operacional: OK, Risco ou Falha.*

*Para eleger a pergunta ideal em cada estágio sem achismos, o algoritmo analisa o **Índice Gini**, identificando a divisão que mais reduz a incerteza e isola o tráfego anômalo.*

*Seu maior benefício é ser uma 'caixa-branca' 100% auditável por equipes de NOC e SRE. Por outro lado, árvores isoladas sofrem com facilidade de **overfitting**, decorando o ruído histórico. Por isso, limitamos sua profundidade máxima através do GridSearchCV, servindo de régua para compararmos com os modelos em conjunto que veremos a seguir."*